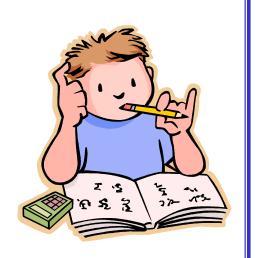
上次课回顾



- 数据挖掘技术的产生
- 数据挖掘概念
- 数据挖掘技术的发展趋势
- 数据挖掘技术的分类问题
- 数据挖掘常用的知识表示模式与方法
- 不同数据存储形式下的数据挖掘问题
- 粗糙集方法及其在数据挖掘中的应用
- 数据挖掘的应用分析




数据挖掘技术的产生





?大量数据、强大算力、实际需求



数据挖掘技术举例——十大算法



- 一、C4.5:分类决策树算法,其核心算法是ID3 算法
- 二、k-means: k-平均算法是解决聚类问题
- 三、SVM:支持向量机
- 四、Apriori:挖掘布尔关联规则频繁项集的算法
- 五、EM:最大期望算法
- 六、PageRank: 网页排名、搜索引擎
- 七、AdaBoost: 自适应增强
- 八、KNN: k-近邻算法
- 九、Naive Baye: 朴素贝叶斯分类器
- 十、CART:分类回归树

投票(可多选)



■ 网上购物时,用户推荐系统可能用到以下哪些方法?




- A、决策树
- B. k-means
- C. SVM
- D. Apriori
- E, EM
- F. KNN
- G. Naive Baye
- H、其它(填写)

购物推荐



个性化推荐系统

是建立在海量数据挖掘基础上的一种高级商务智能平台,以帮助电子商务网站为其顾客购物提供完全个性化的决策支持和信息服务。



购物推荐



- 2、推荐系统有三个重要的模块:用户建模模块、推荐对象建模模块、推荐算法模块。
- 3、主要推荐方法:基于内容推荐、协同过滤推荐、基于关联规则推荐、基于效用推荐、基于知识推荐、基于效用推荐、基于知识推荐、组合推荐



推荐系统



发展历程:

1995年3月,卡耐基.梅隆大学提出了个性化导航系统Web Watcher;斯坦福大学推出了个性化推荐系统LIRA;

2003年,Google开创了AdWords盈利模式,通过用户搜索的关键词来提供相关的广告。AdWords的点击率很高,是Google广告收入的主要来源。

2007年,雅虎推出了SmartAds广告方案。雅 虎掌握了海量的用户信息,如用户的性别、年龄、 收入水平、地理位置以及生活方式等,再加上对用 户搜索、浏览行为的记录,使得雅虎可以为用户呈 现个性化的横幅广告。

第一章 绪论



- 数据挖掘技术的产生与概念
- 数据挖掘的发展趋势
- 数据挖掘技术的分类问题
- 数据挖掘常用的知识表示模式与方法
- 不同数据存储形式下的数据挖掘问题
- 粗糙集方法及其在数据挖掘中的应用
- 数据挖掘的应用分析

第一章 绪论



数据分析是一个交叉学科 数据挖掘 人工智能 大数据 机器学习 数据分析 数据仓库 深度学习 数据统计 商业智能


深度学习三大模型



1、DBN: Deep Belief Network, 深度信念网络

2、CNN: Convolution Neural Network卷积神经网络

3、SAE: Sparse Auto Encoder,稀疏自编码



手写数字体识别



label = 5



label = 0



label = 4



label = 1



label = 9



label = 2



label = 1



label = 3



label = 1



label = 4



label = 3



label = 5



label = 3



label = 6




$$label = 1$$



$$label = 7$$



$$label = 2$$



$$label = 8$$



$$label = 6$$



$$label = 9$$



卷积操作



在重叠的图像和滤波器元素之间逐个进行乘法运算,按

照从左向右、从上到下的顺序。


| 0 | 50 | 0 | 29 |
|----|----|----|----|
| 0 | 80 | 31 | 2 |
| 33 | 90 | 0 | 75 |
| 0 | 9 | 0 | 95 |

| -1 | 0 | 1 |
|----|---|---|
| -2 | 0 | 2 |
| -1 | 0 | 1 |

| 29 | -192 |
|-----|------|
| -35 | -22 |




| 0 | 50 | 0 | 29 |
|----|----|----|----|
| 0 | 80 | 31 | 2 |
| 33 | 90 | 0 | 75 |
| 0 | 9 | 0 | 95 |



CNN——手写数字体识别




特征图(feature map)



相似度2








相似度1

相似度0







相似度1



相似度2

步长Stride











相似度0




















CNN——手写数字体识别



| 特征 | E图 | (fea | ture | map) | 卷 | 积层 | [(加 | 权辅 |)入) | | | 卷积 | 层输出 | | | | | ۸ = | I TT LANE /L | . = | |
|----|----|------|------|------|----|----|-----|----|-----|---|------|------|------|------------------|---|------|------|-----|--------------|-----|---------|
| 2 | 1 | 0 | 1 | | 1 | 0 | -1 | 0 | | (| 0.73 | 0.50 | 0.27 | 0.50 | ١ | 池化 | 层 | 生局 | 3平均池化 | 法 | softmax |
| 0 | 0 | 1 | 2 | +b | -1 | -1 | 0 | 1 | 激 | (| 0.27 | 0.27 | 0.50 | 0.73 | 降 | 0.73 | 0.73 | | 1.17 | | 1 |
| 0 | 0 | 3 | 0 | 7 | -1 | -1 | 2 | -1 | 激活 | 1 | 0.27 | 0.27 | 0.88 | 0.27 | 维 | 0.88 | 0.88 | | | | |
| 0 | 3 | 1 | 1 | | -1 | 2 | 1 | 1 | 7 | (| 0.27 | 0.88 | 0.50 | 0.50 | | | | | | | |
| _ | | T | | | | | | | | | | | | | | | | | | | |
| 0 | 2 | 1 | 1 | N. | -1 | 1 | 0 | 0 | ١ | | 0.27 | 0.73 | 0.50 | 0.50 | 1 | | | | | | |
| 1 | 1 | 1 | 1 | +b | 0 | 0 | 0 | 0 | 激 | | 0.50 | 0.50 | 0.50 | 0.50 | 降 | 0.73 | 0.50 | | 0.5575 | | 0 |
| 0 | 1 | 1 | 1 | 7 | -1 | 0 | 0 | 0 | 活 | | 0.27 | 0.50 | 0.50 | 0.50 | 维 | 0.50 | 0.50 | | 0.5575 | | |
| 0 | 1 | 1 | 1 | | -1 | 0 | 0 | 0 | 7 | | 0.27 | 0.50 | 0.50 | 0.50 | 7 | | | | | | |
| | | | | | | | | | | | | | | H ¹ C | | | | | | | |
| 2 | 1 | 0 | 1 | | 1 | 0 | -1 | 0 | | | 0.73 | 0.50 | 0.27 | 0.50 | | | _ | _ | | | |
| 0 | 0 | 1 | 2 | _ | -1 | -1 | 0 | 1 | 激 | | 0.27 | 0.27 | 0.50 | 0.73 | 降 | 0.73 | 0.73 | | 0.6705 | 1 | |
| 0 | 1 | 2 | 0 | +b | -1 | 0 | 1 | -1 | 活 | | 0.27 | 0.50 | 0.73 | 0.27 | 维 | 0.50 | 0.73 | 7 | 0.6725 | | 0 |
| 1 | 1 | 1 | 2 | | 0 | 0 | 0 | 1 | | | 0.50 | 0.50 | 0.50 | 0.73 | 1 | | 1.00 | | | | |



特征图(feature map)

| 2 | 1 | 0 | 1 | | |
|---|---|---|---|--|--|
| 0 | 0 | 1 | 2 | | |
| 0 | 0 | 3 | 0 | | |
| 0 | 3 | 1 | 1 | | |

卷积层(加权输入)

| | Z ₁₁ ^{F1} | Z F1 ₁₂ | Z ₁₃ ^{F1} | Z ₁₄ ^{F1} | |
|---|--------------------------------------|---------------------------|--------------------------------------|--------------------------------------|----|
| _ | Z F1 ₂₁ | Z F1 22 | Z F1 ₂₃ | Z F1 ₂₄ | 激活 |
| | Z F1 ₃₁ | Z F1 ₃₂ | Z F1 ₃₃ | Z F1 ₃₄ | 函数 |
| | Z F1 41 | Ž ^{į;} 1 ∠42 | Z ₄₃ | Z ₄₄ | |

| α ₁₁ | α ₁₂ F1 | α ₁₃ F1 | α_{14}^{F1} |
|--------------------|--------------------|---------------------------|--------------------|
| α ₂₁ Γ | α ₂₂ F1 | α ₂₃ F1 | α ₂₄ F1 |
| α ₃₁ F1 | α ₃₂ F1 | α ₃₃ F1 | α ₃₄ F1 |
| α_{41}^{F1} | α ₄₂ F1 | α^{F1}_{43} | α ₄₄ |


池化

| 棯 | 池化 | | |
|-----|---------------------------------|---------------------------|------|
| 输出品 | α ₁₁ α ₁₁ | α^{F1}_{21} | 降维,提 |
| 层识 | α ₃₂ F1 | α ₄₂ F1 | 取最大值 |
| 别 | | 7 | |

| α ^{F1} | α ^{F1} ₁₂ | α ₁₃ F1 | α ^{F1} |
|-------------------------------|-------------------------------|-------------------------------|--------------------|
| α ₂₁ F1 | α ₂₂ F1 | α_{23}^{F1} | α ₂₄ F1 |
| α ^{F1} ₃₁ | α ₃₂ F1 | α ^{F1} | αF1 |
| α ^{F1} ₄₁ | α ₄₂ F1 | α ^{F1} ₄₃ | α ₄₄ F1 |

参数共享





不同的卷积核,可以实现边缘检测、图像锐化 、快速均值模糊、高斯模糊



| Operation | Filter | Convolved Image |
|--------------------------|---|--------------------|
| Identity | $\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ | |
| | $ \begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix} $ | |
| Edge detection | $\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$ | |
| | $\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$ | |
| Sharpen | $ \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix} $ | |
| Box blur (normalized) | $\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$ | |

求卷积有何用?





知名的Lena照片

索伯滤波器是是边缘检测器。

| -1 | 0 | 1 |
|----|---|---|
| -2 | 0 | 2 |
| -1 | 0 | 1 |


深度学习三大模型



1、DBN: Deep Belief Network, 深度信念网络

2、CNN: Convolution Neural Network卷积神经网络

3、SAE: Sparse Auto Encoder,稀疏自编码



手写数字体识别实验



MNIST数据集中的每个图像都是28x28像素,包含一个居中的灰度数字。




MNIST训练集训练



```
# 28 * 28 = 784
    input nodes = 784
    hidden nodes = 200
    output nodes = 10
6
    learning rate = 0.1
8
9
    # create instance of neural network
10
    n = neuralNetwork(input nodes, hidden nodes, output nodes, learning rate)
11
```





创建的神经网络--mnist手写数字识别



- 一、加载所需要的库
- 二、定义神经网络类
- 三、创建神经网络对象并用MNIST训练集训练
- 四、用测试集测试准确率
- 五、参数调优过程记录
- 六、测试下自己绘制的字体图片识别效果

加载所需要的库



```
1
 3
 4
    import numpy
 5
 6
    import scipy.special
    import matplotlib.pyplot
 8
    %matplotlib inline
10
11
    # helper to load data from PNG image files
12
    import imageio
13
14
    import glob
15
```

二、定义神经网络类



```
class neuralNetwork:
 2
        def init (self,inputnodes,hiddennodes,outputnodes,learningrate):
 4
 5
            self.inodes = inputnodes
 6
            self.hnodes = hiddennodes
 7
 8
            self.onodes = outputnodes
            self.lr = learningrate
10
11
12
13
14
15
            self.wih = (numpy.random.normal(0.0, pow(self.hnodes,-0.5), (self.hnodes,self.inodes) )
16
            self.who = (numpy.random.normal(0.0, pow(self.onodes,-0.5), (self.onodes,self.hnodes))
17
18
19
            self.activation function = lambda x: scipy.special.expit(x)
20
21
22
            pass
```

```
def train(self,inputs list,targets list):
25
26
            inputs = numpy.array(inputs list,ndmin=2).T
27
            targets = numpy.array(targets list,ndmin=2).T
28
29
30
            hidden inputs = numpy.dot(self.wih,inputs)
31
32
            hidden outputs = self.activation function(hidden inputs)
33
34
35
            final inputs = numpy.dot(self.who, hidden outputs)
36
37
            final outputs = self.activation function(final inputs)
38
40
41
            output errors = targets - final outputs
42
            hidden errors = numpy.dot(self.who.T, output errors)
43
44
45
            self.who += self.lr * numpy.dot((output errors * final_outputs * (1.0 - final_outputs)), numpy.transpose(hidde
46
47
48
            self.wih += self.lr * numpy.dot((hidden errors * hidden outputs * (1.0 - hidden outputs)), numpy.transpose(in
49
```



```
53
        def query(self,inputs_list):
54
55
            inputs = numpy.array(inputs list,ndmin=2).T
56
57
58
59
            hidden inputs = numpy.dot(self.wih,inputs)
60
            hidden outputs = self.activation function(hidden_inputs)
61
62
63
            final inputs = numpy.dot(self.who, hidden outputs)
64
65
            final_outputs = self.activation_function(final_inputs)
66
67
            return final outputs
68
```

三、创建神经网络对象并用MNIST训练集训练



```
# 28 * 28 = 784
    input nodes = 784
    hidden nodes = 200
    output nodes = 10
 6
    learning rate = 0.1
8
9
   # create instance of neural network
10
    n = neuralNetwork(input nodes, hidden nodes, output nodes, learning rate)
```



```
15
    training_data_file = open("mnist_dataset/mnist_train.csv",'r')
16
    training data list = training data file.readlines()
17
    training data file.close()
18
19
20
    epochs = 5
21
    for e in range(epochs):
23
        for record in training data list:
24
25
            all values = record.split(',')
26
            inputs = (numpy.asfarray(all_values[1:]) / 255.0 * 0.99) + 0.01
27
28
            targets = numpy.zeros(output nodes) + 0.01
29
```

四、用测试集测试准确率



```
test data file = open("mnist dataset/mnist test.csv",'r')
 4
    test data list = test data file.readlines()
    test data file.close()
 6
 7
 8
    scorecard = []
10
    for record in test data list:
11
12
        all values = record.split(',')
13
14
        correct label = int(all values[0])
15
        inputs = (numpy.asfarray(all values[1:]) / 255.0 * 0.99) + 0.01
16
17
        outputs = n.query(inputs)
18
19
        label = numpy.argmax(outputs)
20
21
22
        if(label == correct label):
23
24
25
            scorecard.append(1)
        else:
26
27
            scorecard.append(0)
28
        pass
```

五、参数调优过程记录



| 2 | 有效的参数调优说明 | | | | |
|----|-----------|------|-------|--------|-------------------|
| 3 | | | | | |
| 4 | 学习率 | 训练轮数 | 隐藏层节点 | 结果准确率 | 说明 |
| 5 | 0.3 | 1 | 100 | 0.9473 | 初始经验,效果还不错。 |
| 6 | 0.6 | 1 | 100 | 0.9047 | 学习率再增加到0.6,测试准确率下 |
| 7 | 0.1 | 1 | 100 | 0.9502 | 降低学习率到0.1,准确率增加。 |
| 8 | 0.01 | 1 | 100 | 0.9241 | 更低的学习率也不行,应该是限制" |
| 9 | 0.2 | 1 | 100 | 0.9515 | 学习率调到0.2为最优 |
| 10 | 0.2 | 5 | 100 | 0.9611 | 5~7轮迭代是比较好的经验值。测证 |
| 11 | 0.1 | 5 | 100 | 0.9653 | 增加训练轮数,可适当降低学习率, |
| 12 | 0.1 | 5 | 200 | 0.9723 | 增加影藏层节点数,神经网络有更加 |
| 13 | 0.1 | 5 | 500 | 0.9751 | 这个结果已经非常好了! |

六、测试下自己绘制的字体图片识别效果 (28*28)




```
our own dataset = []
4
6
    for image file name in glob.glob('my own images/2828 my own ?.png'):
7
8
9
        label = int(image file name[-5:-4])
10
11
12
        print ("loading ... ", image file name)
13
        img array = imageio.imread(image file name, as gray=True)
14
15
16
        img data = 255.0 - img array.reshape(784)
17
18
19
        img data = (img data / 255.0 * 0.99) + 0.01
20
        print(numpy.min(img data))
21
        print(numpy.max(img data))
22
23
24
        record = numpy.append(label,img data)
25
        our own dataset.append(record)
26
27
28
        pass
```



结果样子如下:

network says 6 Good, match!



作业:



MNIST 数据集可在 http://yann.lecun.com/exdb/mnist/ 获取, 它包含了四个部分:

- Training set images: train-images-idx3-ubyte.gz (9.9 MB, 解压后 47 MB, 包含 60,000 个样本)
- Training set labels: train-labels-idx1-ubyte.gz (29 KB, 解压后 60 KB, 包含 60,000 个标签)
- Test set images: t10k-images-idx3-ubyte.gz (1.6 MB, 解压后 7.8 MB, 包含 10,000 个样本)
- Test set labels: t10k-labels-idx1-ubyte.gz (5KB, 解压后 10 KB, 包含 10,000 个标签)

MNIST 数据集来自美国国家标准与技术研究所, National Institute of Standards and Technology (NIST). 训练集 (training set) 由来自 250 个不同人手写的数字构成, 其中 50% 是高中学生, 50% 来自人口普查局 (the Census Bureau)的工作人员. 测试集(test set)也是同样比例的手写数字数据.

谢谢!